

□ 연구 개요

○ 배경

- 오가노이드(Organoide) 기반 ADMET 데이터는 아직 체계적으로 큐레이션되어 있지 않아, 연구 및 모델링에 즉시 활용하기 어렵다는 한계가 존재한다.
- 관련 실험 정보들은 논문, 본문, 표, 부록, 캡션 등 비정형 형태로 분산되어 있고, 화합물 명칭/구조 표기, 단위, 실험 조건이 문헌마다 상이해 수집 및 정규화 비용이 크며 재현성이 낮다.
- 대규모 언어 모델(LLM)은 텍스트 및 이미지 혼합 문서에서의 정보 추출과 표준 스키마 정렬에 강점을 보인다. 본 연구는 LLM과 RAG, 표, 이미지 추출, 화학 구조 정규화를 결합하여 ADMET 예측 모델에 활용 가능한 데이터셋을 자동 구축하는 프레임워크를 설계 및 구현한다.

○ 관련 연구

- **TVAEs[1]**
 - NCBI 통합 검색, 접근 API로, PubMed 등에서 논문 메타데이터와 오픈 액세스 원문을 자동 수집하여 대규모 문헌 기반 데이터 구축에 활용 가능함
- **nanoMINER[2]**
 - LLM과 멀티모달 분석을 결합한 멀티 에이전트 시스템으로, YOLO(시각 추출)·GPT-4o(텍스트-시각자료 연계)·ReAct 조율을 통해 나노소재 문헌의 비정형 데이터를 자동 구조화하고, 화학식·결정 구조·표면 특성 등 핵심 파라미터를 정밀 추출함
- **ChemMiner[3]**
 - LLM 기반 멀티 에이전트 프레임워크로, 동지시어(Coreference) 해소를 핵심으로 하여 약어·기호·대용 표현을 단일 개체로 묶는 매핑 사전을 구축함. 이런 사전 기반 정규화를 통해 JSON 구조의 준수도(데이터 타입, 단위 일치, 값 범위, 형식 유효성)가 향상됨.
- **StructRAG[4]**
 - 질의 시점에 문서를 구조로 변환해 활용하는 RAG로, 사용자 질문을 의도 및 슬롯으로 분해하고 문서에서 얻은 구조화된 지식을 하이브리드 검색(Retrieval)으로 회수한 뒤, 사전 정의된 출력 규격에 맞춰 응답을 조립한다. 일관된 표/JSON 형식과 근거(출처)를 함께 제공함.

○ 기존 연구의 한계점 및 개선 사항


- 기존 연구들에서는 논문 곳곳에 흩어진 사진, 표 같은 비정형 데이터를 한 번에 모으고 정보를 정리하기 어려웠으며, 실험 결과들의 단위, 표기, 약어가 제각각이라 오류와 혼동이 많음.
- 이에 nanoMINER, ChemMiner 등은 실험 연구들에서 지식 추출을 보여주지만, 오가노이드 관련 ADMET에 맞춰진 기법이나 규칙이 부재하며, 지식 추출 단계에서만 멈추고, 사용자가 원하는 조건에 맞춰 재구성 해주는 단계가 결여됨.
- 특히, ADMET 예측 모델의 훈련 데이터로 사용하기 위해서는 문헌들에 나오는 수치를 자동으로 정규화 할 필요가 있으며, 자체적인 질의응답 시스템을 도입하여 원하는 데이터를 정확히 얻고 검증 할 수 있는 시스템이 필요함.

○ 연구 목표

- 이에 본 연구에서 수행하고자 하는 ADMET-RAG는 PubMed 논문을 자동으로 수집하고, 멀티 모달 지식 추출을 통해 본문, 표, 그림을 추출한 뒤 약어에 대한 사전 및 실험 데이터의 단위를 정규화하여 ADMET 전용 기법에 저장한다. 이후 구조화된 RAG를 이용하여 질의를 슬롯화 및 검증하여 훈련 데이터로 사용할 수 있는 CSV 파일과 파일에 대한 보충 설명 자료를 제공할 수 있는 프레임워크를 개발한다.

□ 주요 설계

○ ADMET-RAG 설계도



○ 수도 코드 (Pesudo code)

Input: User query for ADMET data

Output: ADMET dataset (CSV)

function ADMET RAG (Query):

 Fetch PDFs via Entrez

for each PDF **do**

 Parse PDFs into texts, figures using layout analysis, OCR, and YOLO

 Extract FigureData from figures with the Vision agent

 Extract TextData form text with the Main agent

 Build a CorefDict from FigureData and TextData with the Coreference

 Generate JSON using FigureData, TextData, and CorefDict with the Main agent

 Chunk the JSON

for each Chunk **do**

 Embed each chunk

 Upsert the embeddings into the vector database

end for

end for

 Decompose the query into sub-questions

for each sub-question **do**

 Measure similarity and coreference to identify intent.

 Query the database with the RAG agent and generate schema-aligned answers

end for

 Aggregate and review the answers

return ADMET dataset (CSV)

□ 2단계 개발 일정

구분	내용	7	8	9	10	11	12
1	논문, 보충자료 수집 방법 구현						
2	논문 자료 전처리 자동화 구현						
3	Multi-Agent 오케스트라 구현						
4	ADMET-RAG 구현						

□ 참고문헌

1. Database resources of the National Center for Biotechnology Information, Nucleic Acids Research, 38(Database issue), D5 - D16, 2010
2. Agent-based multimodal information extraction for nanomaterials, npj Computational Materials, 11, 194, 2025
3. ChemMiner: A Large Language Model Agent System for Chemical Literature Data Mining, arXiv preprint, 2024
4. StructRAG: Boosting knowledge intensive reasoning of LLMs via inference-time hybrid information structurization, ICLR, 2025